ANÁLISIS DE TEXTO · BERTopic

¿De qué hablan las reseñas de Letterboxd?

Modelado de tópicos en reseñas en español

Reporte reproducible | 30 de octubre de 2026

3,235 segmentos · 1,137 reseñas · 241 películas

El análisis de 3,235 segmentos españoles de reseñas de Letterboxd muestra una fuerte sensibilidad a los parámetros. La configuración A descubre 52 grupos, con 47.30% de outliers; B obtiene 6, con 24.82%. B ofrece una síntesis legible, pero su grupo principal reúne 54.19% de los segmentos y resulta demasiado amplio. Los grupos más específicos remiten a directores, películas y tradiciones cinematográficas; no aparecen categorías limpias y separadas de guion, actuación o fotografía. El hallazgo es una cartografía exploratoria con límites, no una clasificación validada de las opiniones de toda la plataforma.

Pregunta de investigación

¿Qué temas emergen en las reseñas en español de una muestra de películas muy valoradas, y cómo cambian al exigir grupos de mayor tamaño?

Entrega y trazabilidad

Se incluyen corpus, identificadores de origen, asignaciones, tablas de get_topic_info, ejemplos completos, visualizaciones interactivas y código. Todos los conteos proceden de la ejecución guardada; los nombres e interpretaciones son una lectura analítica asistida por IA.

El código y la guía de reproducción están disponibles en el repositorio de GitHub indicado al final del reporte.

1. Corpus y segmentación

Se utilizó el dataset de Riyosha, Letterboxd Movie Reviews (~90,000), versión 1, actualizado el 5 de septiembre de 2024 [1]. Contiene reseñas y valoraciones de 250 películas del listado superior de Letterboxd en la captura. No se extrajeron datos de cuentas ni se utilizó una API de pago.

Los metadatos del publicador declaran CC0; esto no verifica los derechos de cada autor. El archivo no incluye nombres de usuario ni enlaces individuales. Se conservan Movie, fecha y posición original como trazabilidad; los IDs Rxxxxx permiten volver al CSV. La fecha de descarga fue el 30 de octubre de 2026.

Etapa	Registros
CSV original	90016
Texto no vacío	90003
Reseñas únicas (texto normalizado)	89698
Candidatas por vocabulario español	2956
Español con puntuación ≥ 0.90	1175
Reseñas con ≥ 20 palabras	1152
Ventanas elegibles	3098
Ventanas muestreadas (semilla 42)	3000
Segmentos finales por límite del tokenizer	3235

La normalización decodifica HTML y elimina etiquetas, URLs y espacios repetidos; conserva acentos y puntuación para embeddings. Los duplicados se detectan ignorando mayúsculas. El prefiltro exige cuatro apariciones de un vocabulario español explícito; después langdetect selecciona es con puntuación ≥ 0.90 y semilla 42. Esa puntuación no equivale a una probabilidad calibrada de idioma correcto.

2. Criterio de segmentación y alcance

La reseña es la unidad de origen. Se excluyen reseñas de menos de 20 palabras, con poco contexto. Las demás se dividen en ventanas consecutivas de hasta 80 palabras, sin solapamiento. Una cola de menos de 20 palabras se adjunta a la anterior (máximo 99). Se muestrean 3,000 ventanas al azar por coste computacional, antes de ajustar el tokenizer.

Las ventanas que exceden 128 tokens, incluidos los especiales, se subdividen recursivamente por palabras. Por eso el resultado final tiene 3,235 segmentos. El máximo observado fue 128 tokens: no se recortó silenciosamente el texto al calcular embeddings.

Este criterio admite reseñas cortas y largas con una regla común, pero puede cortar oraciones y separar una negación de su contexto. Los fragmentos no son observaciones independientes: una reseña extensa aporta varios. El muestreo por ventanas favorece reseñas largas; las frecuencias describen fragmentos de esta muestra, no porcentajes de usuarios ni de toda la plataforma.

Estadística final	Valor
Reseñas distintas	1137
Películas distintas	241
Palabras por segmento: media	66.2
Mediana	80
Mínimo / máximo	20 / 99
Cuartiles 25% / 75%	48 / 80

Sesgos y restricciones

El corpus favorece cine apreciado y reseñas disponibles en la captura de 2024. El filtro español puede omitir textos con pocas palabras funcionales, variación dialectal o mezcla de idiomas, y no se validó contra un conjunto de etiquetas humanas. No se tradujeron reseñas. No se infiere nacionalidad a partir del idioma. La imagen del enunciado en Canvas no fue accesible; se utiliza el criterio explícito anterior.

3. Metodología

Se eligió **sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2** [2]. Produce vectores de 384 dimensiones y admite español entre sus idiomas. Es una opción multilingüe compacta, adecuada para ejecutar localmente y agrupar similitud semántica sin entrenar un clasificador. No es un modelo específico de cine ni demuestra ser superior a todos los modelos españoles; no se realizó un benchmark de embeddings.

Se conservó el contexto original para el encoder y se normalizaron los vectores. El flujo fue embeddings → UMAP → HDBSCAN → CountVectorizer → c-TF-IDF. UMAP reduce a cinco dimensiones con distancia coseno; HDBSCAN busca grupos densos. c-TF-IDF caracteriza cada grupo mediante términos distintivos [3]. Las stopwords españolas de NLTK se aplican exclusivamente al vectorizador y su copia se incluye en la entrega [5]. No se eliminaron nombres de películas: interesa comprobar su influencia.

Parámetro	A: exploratoria	B: grupos mayores
UMAP n_neighbors / n_components	15 / 5	15 / 5
UMAP min_dist / metric	0 / cosine	0 / cosine
UMAP random_state / n_jobs	42 / 1	42 / 1
HDBSCAN min_cluster_size	15	35
HDBSCAN min_samples	5	10
HDBSCAN metric / método	euclidean / eom	euclidean / eom
CountVectorizer ngram_range	(1, 1)	(1, 2)
CountVectorizer min_df	2	2
nr_topics	None	None

A permite recuperar grupos pequeños; B exige mayor soporte y añade bigramas para representar expresiones. Se cambian varios parámetros como comparación exploratoria, por lo que no se atribuye un efecto causal a uno solo. ngram_range modifica la representación léxica; UMAP/HDBSCAN determinan los grupos. No se fuerza un número final con nr_topics [4]. Se comparten exactamente los mismos embeddings y segmentos.

4. Comparación de configuraciones

Medida	A	B
Tópicos (sin -1)	52	6
Outliers	1530	803
Outliers (%)	47.30	24.82
Silhouette coseno	0.055	0.012
Diversidad top-10	0.846	0.750
Concentración por película	0.340	0.088

Silhouette se calcula en embeddings originales normalizados, solo con segmentos asignados, sobre hasta 2,000 observaciones con semilla 42; no mide coherencia humana ni compara la misma submuestra si cambia la cobertura. Diversidad es términos únicos / (10 × tópicos): los bigramas pueden elevarla mecánicamente. Concentración es la suma, por tópico, del número de segmentos de su película más frecuente, dividida entre todos los asignados; un valor alto sugiere agrupación por título.

ARI entre particiones: 0.113 incluyendo -1 como etiqueta, y 0.087 sobre los 1,493 segmentos asignados en ambas. ARI mide concordancia, no calidad; el primer valor trata los outliers como un grupo aunque no constituyan un tópico.

Pasar de A a B reduce 52 grupos a 6 y los outliers de 47.30% a 24.82%, una disminución de 22.47 puntos porcentuales. La mayor cobertura no implica mejores temas: silhouette baja de 0.055 a 0.012 y la diversidad top-10 de 0.846 a 0.750. La concentración por película baja de 0.340 a 0.088 porque B mezcla más títulos dentro de grupos grandes. La concordancia ARI de 0.087 en los asignados por ambas confirma que las particiones no son intercambiables. En HDBSCAN el aumento de tamaño mínimo no garantiza más outliers: la selección de grupos sobre la jerarquía puede favorecer grupos mayores que absorban más observaciones.

Selección para el análisis detallado

Se presenta B en detalle como síntesis de seis macrogrupos y para examinar explícitamente sus fallos. Esta elección es expositiva, no una afirmación de que B sea mejor: A logra mayor separación y permite inspeccionar temas pequeños, a costa de fragmentación y menor cobertura. El catálogo A incluido contiene nombres propios y tres segmentos íntegros para cada uno de sus 52 tópicos. Ninguna configuración resuelve satisfactoriamente el objetivo más exigente de distinguir aspectos cinematográficos transversales sin mezclar películas o estilos discursivos.

No hay etiquetas verdaderas ni evaluación humana independiente. Las métricas permiten describir compromisos; no sustentan una afirmación de exactitud temática o superioridad general.

5. Tabla de tópicos: configuración B

Resumen de get_topic_info con nombres interpretativos propios. El CSV incluido conserva las columnas completas y los nombres automáticos. Los porcentajes usan todos los segmentos como denominador, incluido -1.

ID	Nombre interpretativo	n	%	Términos c-TF-IDF
-1	Sin grupo denso (outliers)	803	24.8	película, vida, historia, ser, si
0	Valoración general y experiencia del cine	1753	54.2	película, cine, si, tan, ser
1	Cine japonés: Kurosawa y Slam Dunk	365	11.3	kurosawa, película, dersu, ser, tan
2	Ford, western y el mito de Liberty Valance	128	4.0	ford, the, valance, liberty, liberty valance
3	Cine de autor, espiritualidad y forma audiovisual	75	2.3	tarkovsky, película, tarr, banda sonora, sonora
4	Lynch y análisis simbólico de personajes (mixto)	56	1.7	lynch, dos, miss, cooper, miss cooper
5	Simbolismo y decadencia: eje La dolce vita	55	1.7	marcello, arte, fiesta, vida, obra

Los IDs son locales al ajuste y no tienen significado ordinal. El nombre interpretativo se asignó después del modelado al leer términos y ejemplos; no intervino en el clustering.

6. Visualizaciones e interpretación

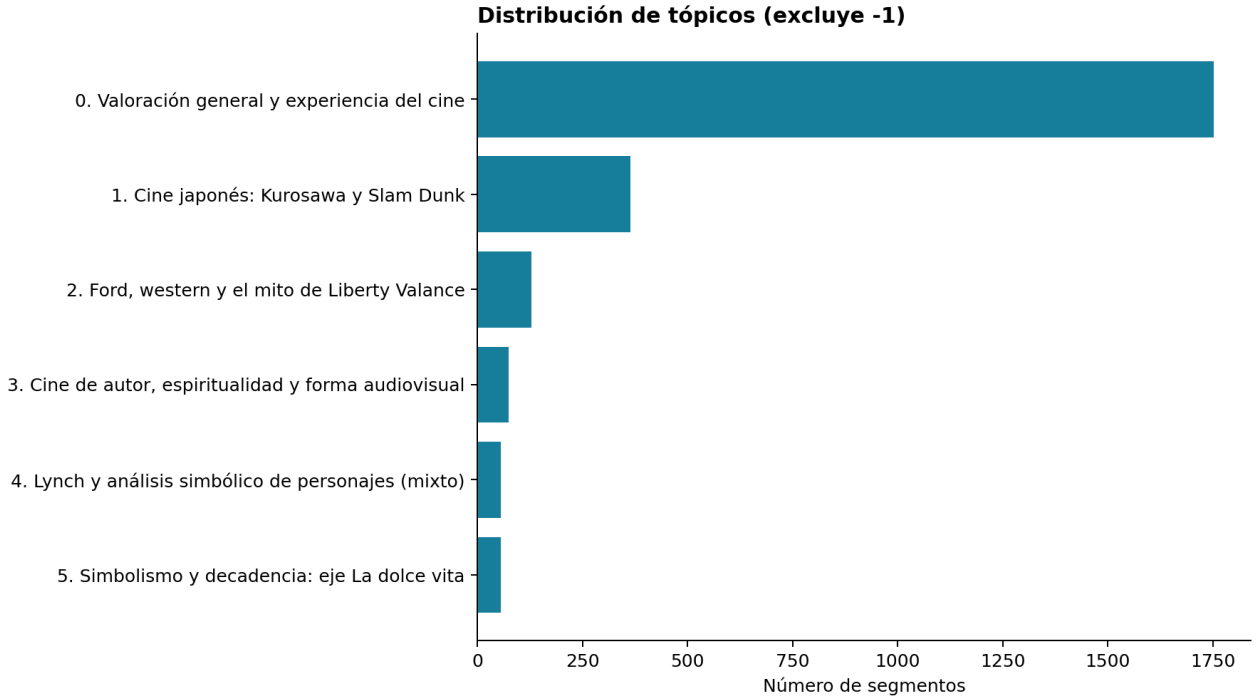


Figura 1. Tamaño de los tópicos, excluyendo los outliers. Un segmento puede reflejar más de un tema, pero aquí tiene una sola etiqueta.

El grupo 0 contiene 1,753 segmentos: 54.19% del total y 72.08% de los asignados. Su tamaño domina la figura y revela un grupo residual de crítica general, no un tema específico. El grupo 1 reúne 365 segmentos (11.28%), mientras los restantes tienen entre 55 y 128. Por tanto, contar seis tópicos no implica seis asuntos de peso similar. Las frecuencias miden ventanas de texto; una reseña larga aporta más de una y no equivale a más personas interesadas.

7. Relaciones entre tópicos

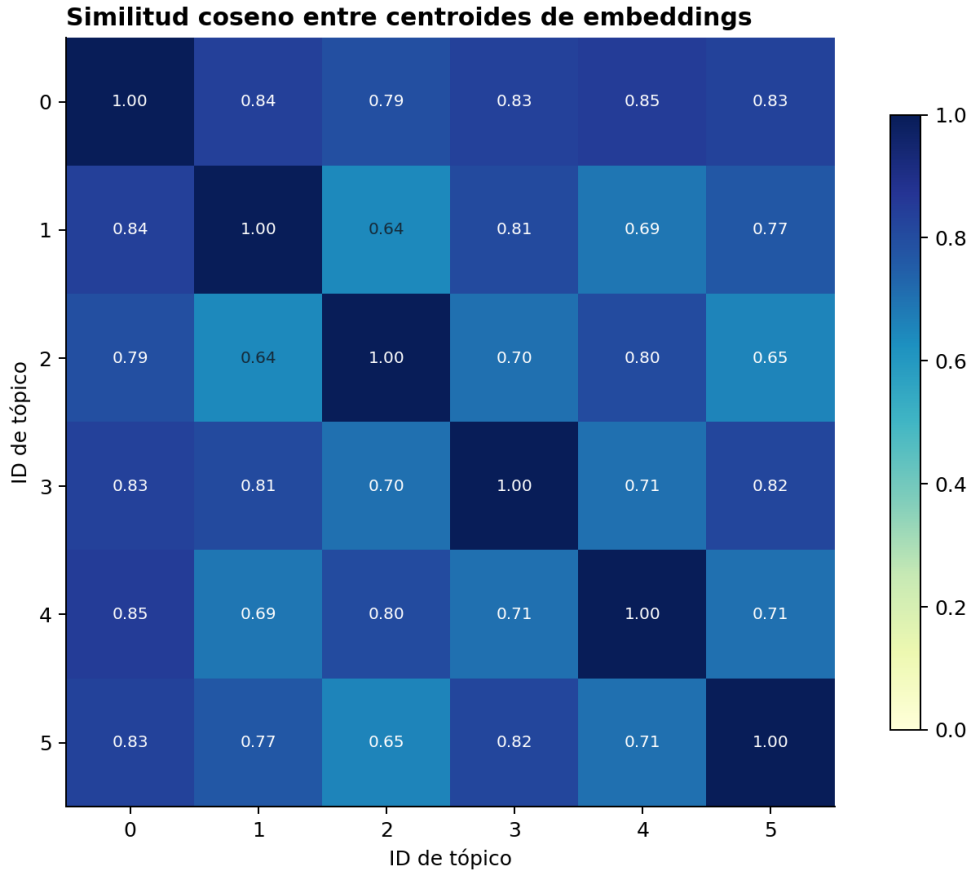


Figura 2. Similitud coseno entre el promedio de embeddings de cada tópico. La diagonal vale uno por construcción. Esta figura usa embeddings originales, no distancias UMAP ni una escala de causalidad.

Todas las similitudes entre grupos son relativamente elevadas (0.644 a 0.849): comparten idioma, dominio y vocabulario cinéfilo. El par 0-4 alcanza 0.849 y 0-1, 0.838, coherente con el carácter genérico del grupo 0. El par 1-2 es el menor (0.644), compatible con la diferencia entre discusión del cine japonés y del western de Ford. El valor alto 3-5 (0.817) sugiere solapamiento entre lecturas de cine de autor y análisis simbólico. Los centroides y la anisotropía del espacio pueden elevar la similitud; esta figura no demuestra que los grupos deban fusionarse ni establece una prueba de significación.

8. Términos que caracterizan los grupos

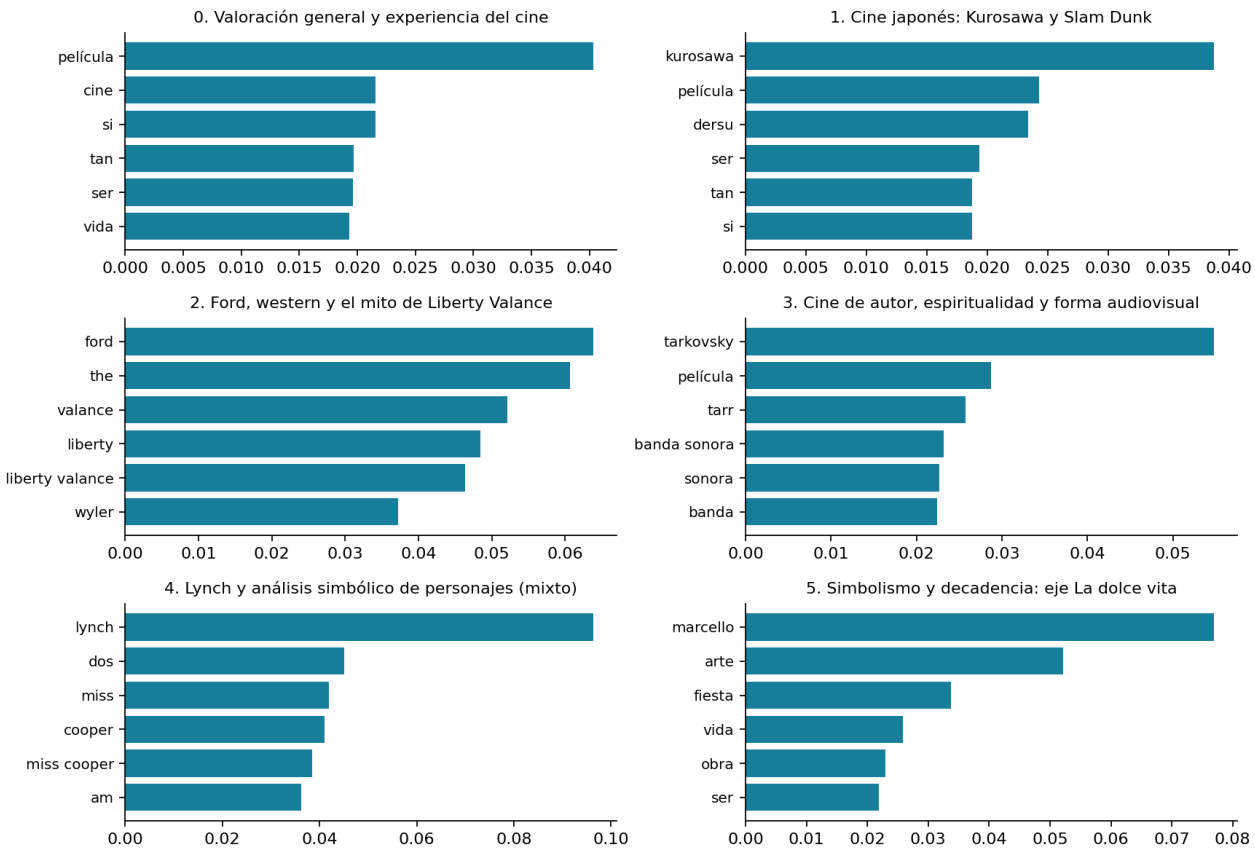


Figura 3. Seis términos con mayor peso c-TF-IDF por tópico. El peso representa distintividad dentro del corpus; no es probabilidad del tópico ni conteo bruto.

Ford, Valance y Liberty dan un referente concreto al grupo 2. Kurosawa y Dersu caracterizan el grupo 1, aunque sus ejemplos incluyen Slam Dunk; por ello no conviene nombrarlo solo Dersu Uzala. Banda sonora en el grupo 3 muestra el aporte de un bigrama, sin convertirlo en un tópico exclusivo de música. En el grupo 4 coexisten Lynch y Miss Cooper, señal de mezcla entre filmes distintos. Película, cine, si y tan en el grupo 0 ofrecen poca especificidad; las stopwords españolas reducen palabras funcionales, pero no eliminan automáticamente términos de dominio ni todas las variantes lingüísticas. Los nombres deben apoyarse en lectura contextual, no solo en las primeras palabras.

9. Segmentos representativos y lectura crítica

Se muestran tres segmentos seleccionados por get_representative_docs para cada tópico. Son fragmentos textuales reales, no paráfrasis ni ejemplos inventados. Los IDs permiten localizar el texto completo en las asignaciones; las películas se identifican por el slug del dataset. Los extractos se limitan a 55 palabras para lectura; [...] indica recorte editorial.

Tópico 0. Valoración general y experiencia del cine

1753 segmentos (54.2% del corpus). Términos: película, cine, si, tan, ser, vida, historia, ver, cada, vez.

Grupo amplio de juicios sobre dirección, guion, fotografía, actuaciones y efecto emocional. Los ejemplos de The Ascent, The Cranes Are Flying y Red Beard comparten valoración cinematográfica, pero no un aspecto único. Contiene 867 reseñas y 232 películas, casi todo el abanico de la muestra.

Ejemplo 1 · R21406_S00_P0 · the-ascent

> Qué nivel de dirección, guion, fotografía, interpretaciones... Sin dudar uno de los mejores retratos de guerra que he visto, pero más que eso, de lo que significa ser humano y de la misma inhumanidad, sin llegar a ser tan explícita como la hecha unos años más tarde por su esposo, Idi i smotri, una película [...]

Ejemplo 2 · R16435_S00_P0 · the-cranes-are-flying

> Que película más brillante a nivel técnico y de historia, se me hace imposible creer que una película de los 50’s tenga tantos movimiento de cámara, los planos secuencias y los travelings son una maldita de locura. Y también me gusta mucho como la película experimenta en ciertas escenas que hasta incluso rozan el surrealismo. [...]

Ejemplo 3 · R30366_S00_P0 · red-beard

> No se cómo describir el sentimiento que tuve al ver Barbarroja, fue una película muy introspectiva, melancólica, pero a la vez muy hermosa.Lo que la hace tan maravillosa, creo yo, es que la historia va mucho más allá de lo que se ve solo en pantalla, toda la película transcurre en un hospital, y ahí [...]

Alcance del nombre

La etiqueta es descriptiva y deliberadamente general. El grupo funciona como un conjunto heterogéneo de críticas y no debe presentarse como un tópico nítido. Sus 1,753 segmentos explican buena parte de la baja separación de B.

Tópico 1. Cine japonés: Kurosawa y Slam Dunk

365 segmentos (11.3% del corpus). Términos: kurosawa, película, dersu, ser, tan, si, shinji, cine, historia, obra.

Combina discusiones sobre Kurosawa, Dersu Uzala, drama humano y adaptaciones japonesas de animación. Dos ejemplos representativos son de The First Slam Dunk y uno de Ikiru. Dersu Uzala es la película más frecuente (55 segmentos), seguida de The First Slam Dunk (43). El vínculo es una tradición y un universo de referencias, más que una técnica cinematográfica.

Ejemplo 1 · R77369_S00_P0 · the-first-slam-dunk

> “Hasta el final, nunca pierdas la esperanza. Es cuando te rindes que el partido termina”.The First Slam Dunk demuestra que Takehiko Inoue no solo es uno de los mejores mangakas de todos los tiempos sino también un increíble director al hacer de su película debut un drama emotivo, emocionante y tan gratificante.lo que realiza el [...]

Ejemplo 2 · R04984_S01_P0 · ikiru

> las obras maestras del cine japonés.Sinceramente el cine de Kurosawa es asombroso, sin embargo debo confesar que me dormi en una parte de la película y es por la duración. Si bien Kurosawa es un hombre ambicioso, como quien diga es Stanley Kubrick japones. La mejor manera de ver y entender su cine es estando [...]

Ejemplo 3 · R77345_S00_P0 · the-first-slam-dunk

> La amé completamente, la pelicula puede ser mucho mejor, aprovechar de manera mas inteligente los tiempos, banda sonora, pero está llena de sentimiento, el partido no es tan bueno ni emocionante como en el manga, está lejos, pero el solo hecho de ser Slam Dunk me hace querer llorar, poder ver esos momentos del manga [...]

Alcance del nombre

Reúne 181 reseñas y 48 películas, incluidas comparaciones entre obras. No todos los miembros tienen por qué ser japoneses, ni Kurosawa y Slam Dunk comparten necesariamente un tema concreto. El nombre comunica el centro interpretativo y no una regla de pertenencia.

Tópico 2. Ford, western y el mito de Liberty Valance

128 segmentos (4.0% del corpus). Términos: ford, the, valance, liberty, liberty valance, wyler, john, oeste, wayne, man who.

Es el grupo con referente más reconocible: John Ford, John Wayne y el western, con lecturas de The Man Who Shot Liberty Valance como cierre del género y revisión de sus mitos. Los ejemplos mencionan violencia, legitimidad y personajes concretos. Abarca 37 reseñas y 18 películas; 75 de 128 segmentos son de Liberty Valance.

Ejemplo 1 · R62780_S09_P0 · the-man-who-shot-liberty-valance

> y el que quema desesperado Tom Doniphon en The Man Who Shot Liberty Valance. Y los crímenes. Porque esa lucha por tener una vida digna se construye sobre la tragedia. No la de la muerte de un desecho humano como Liberty Valance (al que Ford otorga un hilo de humanidad al hacerlo temblar y balbucear [...]

Ejemplo 2 · R62649_S08_P1 · the-man-who-shot-liberty-valance

> una de sus obras más crepusculares: The Man Who Shot Liberty Valance. No solo la película sostiene estas concepciones anteriormente marcadas, sino que, a diferencia de sus anteriores rodajes, aquí John Ford honra y le otorga el lugar protagónico a

Ejemplo 3 · R62828_S00_P0 · the-man-who-shot-liberty-valance

> 23 años después de revolucionar la forma de hacer un Western al dirigir la brillante Stagecoach, John Ford cierra el arco con The Man Who Shot Liberty Valance, una película que se siente como un "déjalo morir" para el género. Mejor dicho, que ES un "déjalo morir" con todas las letras.Miremos a John Wayne: el [...]

Alcance del nombre

No es exclusivamente un grupo de westerns: The Best Years of Our Lives aporta 28 segmentos. Los fragmentos con análisis clásico y referencias compartidas pueden quedar cerca aunque pertenezcan a otras películas. El nombre no explica la totalidad del grupo.

Tópico 3. Cine de autor, espiritualidad y forma audiovisual

75 segmentos (2.3% del corpus). Términos: tarkovsky, película, tarr, banda sonora, sonora, banda, cada, pieza, cine, historia.

Los ejemplos conectan Tarkovsky con arte y religión, examinan fotografía y sonido en Woman in the Dunes, y relacionan The Sacrifice con Bergman. Los términos Tarkovsky, Tarr y banda sonora sugieren una lectura de autores, atmósferas y recursos formales. El grupo contiene 51 reseñas y 28 películas.

Ejemplo 1 · R13165_S00_P0 · andrei-rublev

> Hace tiempo empecé a ver las películas de Tarkovsky, empecé con Mirror (Lo cual ahora me doy cuenta que fue una mala elección xD) luego vi La infancia de Iván, que me había gustado pero no encantado. Ahora vi Andrei Rublev, pensé que me aburría y vaya que equivocado estaba… Religión - arte - opresión [...]

Ejemplo 2 · R10570_S02_P0 · woman-in-the-dunes

> la transformación del ser dependiendo del entorno que lo rodea. La fotografía y la dirección son hermosos y precisos, ni siquiera en Stalker de Andrei Tarkovsky las dunas, la arena y el agua tenían tanto nivel estilístico sirviendo además como un recurso simbólico y asfixiante. Aunque lo que, sin lugar a duda, se lleva todo [...]

Ejemplo 3 · R44487_S02_P0 · the-sacrifice

> entregarse a la espiritualidad por completo. Ese final con el niño hablando y que la película esté dedicada al propio hijo de Tarkovsky, es lo que me hace pensar.Está claro que el cine de Tarkovsky es único y que tiene una escencia y poesía como ningún otro, pero The Sacrifice creo que se trata de [...]

Alcance del nombre

No es un tópico puro de espiritualidad ni de música. Amadeus y Nostalghia aportan ocho segmentos cada una; otros títulos añaden registros distintos. La etiqueta reúne conexiones interpretativas amplias, y su similitud con el grupo 5 aconseja cautela.

Tópico 4. Lynch y análisis simbólico de personajes (mixto)

56 segmentos (1.7% del corpus). Términos: lynch, dos, miss, cooper, miss cooper, am, powell, cine, película, david lynch.

Los términos y dos ejemplos apuntan a The Elephant Man y David Lynch. El tercer ejemplo enumera simetrías de The Night of the Hunter, con Miss Cooper y Powell. Mulholland Drive aporta 21 segmentos, The Elephant Man 13 y The Night of the Hunter siete. Se agrupan lecturas de personajes y simbolismo, sin una unidad clara de autor.

Ejemplo 1 · R61400_S11_P0 · the-night-of-the-hunter

> Black Sunday de Mario Bava, la película se va a estructurar en una serie de simetrías que representen estas dos deidades y el enfrentamiento de ambas. Para eso el número 2 (dos) va a ser una constante a lo largo y ancho del filme. Ejemplos:Dos esposos (Harper y Powell), dos madres (Cooper y Willa), dos [...]

Ejemplo 2 · R74719_S00_P0 · the-elephant-man

> "I am not an elephant! I am not an animal! I am... a human being! I am a MAN!"La segunda película de Lynch es un contraste total con "Erasehead" al dejar atrás una historia experimental y llena de simbolismo para en su lugar contar una bastante clara tanto en su relato como en el mensaje [...]

Ejemplo 3 · R74672_S00_P0 · the-elephant-man

> La muerte de John Hurt me entristeció mucho. Era un actor al que le tenía harto cariño. Imposible no. Y bueno, tenía ganas de revisar The Elephant Man, por ser una de las películas de Lynch que menos he visto. No sé por qué.Por lo general se le etiqueta a The Elephant Man como Lynch [...]

Alcance del nombre

Es uno de los grupos menos coherentes: la presencia de Lynch no explica el análisis de otra película. Se mantiene la palabra mixto para evitar atribuir al modelo una categoría autoral limpia. Sus 56 segmentos proceden de 26 reseñas y 12 películas.

Tópico 5. Simbolismo y decadencia: eje La dolce vita

55 segmentos (1.7% del corpus). Términos: marcello, arte, fiesta, vida, obra, ser, natasha, andrei, artista, actriz.

Los tres ejemplos analizan motivos de La dolce vita: Marcello, fiestas, religión, agua y decadencia. Sin embargo, todos son fragmentos de la misma reseña R55133. La dolce vita aporta 13 segmentos de los 55 del grupo; el resto se reparte entre otras películas. El nombre identifica su representación más visible, no un conjunto exclusivo de Fellini.

Ejemplo 1 · R55133_S03_P0 · la-dolce-vita

> corrompe algo sagrado..Marcello es parte de una sesión de espiritismo de la que los invitados se burlan en el castillo aristocrático. Todos terminan en una procesión mientras se retiran (se retiran de la tradición)..Durante la fiesta final, la cual presenta a un Marcello perdido del todo tras la muerte de Steiner (el padre que no [...]

Ejemplo 2 · R55133_S04_P0 · la-dolce-vita

> en la casa de la prostituta..La fuente de agua en donde se meten Sylvia y Marcello..La lluvia en el pueblo de los niños que dicen ver a la Virgen María..El padre de Marcello descompuesto por beber demasiado y al que este le ofrece de beber un vaso de agua..Los sonidos de tormenta en la fiesta [...]

Ejemplo 3 · R55133_S06_P0 · la-dolce-vita

> primero a la casa de la bailarina y el segundo a la estación de trenes. .Los autos que detienen Marcello y Nico para ir a la fiesta del castillo aristocrático. .La carrera de autos con la que Marcello y compañía llegan a la fiesta final. Allí Marcello se monta a una mujer a gatas, el [...]

Alcance del nombre

La repetición de una misma reseña en los tres ejemplos revela el peso de textos largos en c-TF-IDF y en la selección de representantes. El grupo incluye 38 reseñas y 31 películas; no puede inferirse acuerdo de tres autores a partir de esos ejemplos. El aparente eje de La dolce vita sobrerrepresenta una voz.

10. Outliers: qué significan y qué se hizo

La configuración B dejó 803 segmentos en -1 (24.82%). Se conservaron en las asignaciones y en los denominadores del reporte. No se borraron, ni se reasignaron automáticamente. -1 indica que HDBSCAN no encontró pertenencia suficientemente densa; no significa reseña inválida, idioma incorrecto o ausencia de contenido.

Los tres ejemplos aleatorios de abajo (semilla 42) hablan de Bergman, la comedia antibélica de Chaplin y la experiencia de ver Sátántangó. Tienen contenido interpretable: no se trata simplemente de ruido textual. Conservarlos evita hacer pasar las fronteras de densidad por una evaluación del valor de las reseñas. También muestra que la falta de un tópico de filosofía o de guerra en B no significa ausencia de esos asuntos en el corpus. Los ejemplos proceden de una selección aleatoria, a diferencia de los representativos elegidos por BERTopic.

R31166_S00_P0 · the-seventh-seal

> La película más emblemática y famosa de Ingmar Bergman; el séptimo sello es un hito del cine, no se trata de una película de miedo más bien es una película filosófica sobre el significado de la vida y la muerte y la duda de lo [...]

R41734_S00_P0 · the-great-dictator

> Leyendo uno de los libros sobre cine que me prestaron mis jefes en las pasantías, aproveche y decidí ver esta cinta de Charles Chaplin a la cual siempre le tuve curiosidad. No se como este hombre hizo una comedia tan efectiva que se mezcle muy [...]

R26421_S14_P0 · satantango

> me lo están contando, si no lo que me están intentando decir. Y en estas siete horas, Tarr dice una cantidad increíble de cosas. Y durante siete horas, deberías intentar escucharlo.Feliz año.

BERTopic ofrece reducción de outliers por probabilidades, distribuciones o similitud [6]. Se optó por conservarlos porque forzar cobertura podría ocultar la heterogeneidad. Una extensión sería comparar reasignaciones con umbral de similitud y validación manual, informando por separado cobertura original y posterior.

11. Discusión y conclusiones

Los grupos que mejor se sostienen tienen referentes identificables. El 2 reúne western y John Ford: 75 de sus 128 segmentos proceden de The Man Who Shot Liberty Valance (58.59%). Sus tres ejemplos pertenecen a reseñas distintas de esa película. Es una categoría útil para localizar esa conversación, pero su nombre depende de la obra y no corresponde a un aspecto universal del cine.

El grupo 1 también tiene sentido como aproximación al cine japonés, desde Kurosawa hasta Slam Dunk, pero abarca 48 películas y sus ejemplos no describen un único problema narrativo o técnico. El grupo 3 conecta cine de autor, espiritualidad y lectura formal. Estos nombres señalan familias de discusión; no prueban homogeneidad temática de todos sus miembros.

Los resultados menos convincentes son el grupo 0, genérico y dominante, y el 4, que mezcla Lynch con análisis de The Night of the Hunter. El 5 parece muy específico al leer sus ejemplos sobre Marcello, pero los tres fueron extraídos de una sola reseña de La dolce vita. El grupo realmente contiene 55 segmentos de 38 reseñas y 31 películas. La representación puede amplificar una voz extensa y sugerir una coherencia mayor de la que existe en el conjunto.

En A aparecen microgrupos sobre crítica cinematográfica, Evangelion, identidad, Holocausto o neorrealismo, junto con grupos mixtos y otros centrados en escenas o personajes. La separación media mejora respecto de B, pero sigue siendo baja; sus nombres tampoco deben confundirse con una taxonomía estable. Ambos ajustes dejan claro que la similitud semántica, la densidad y los términos distintivos no garantizan tópicos interpretativamente uniformes.

La conclusión sustantiva es que en esta muestra la conversación se organiza parcialmente alrededor de autores, títulos y tradiciones, y que una solución gruesa absorbe muchas valoraciones generales en un solo grupo. La conclusión metodológica es priorizar inspección de ejemplos, cobertura y sensibilidad a parámetros sobre el mero número de tópicos. Se cumplen las dos ejecuciones y su análisis; sus debilidades son resultados del experimento que deben conservarse visibles.

Limitaciones y siguientes pasos

Además del sesgo de películas bien valoradas y del filtrado de idioma, hay dependencia entre segmentos de una misma reseña, posible repetición de citas y un solo encoder. La deduplicación exacta no elimina paráfrasis. No se evaluó estabilidad con otras semillas ni con un corpus externo. La precisión de los nombres se basa en lectura asistida, sin anotadores independientes. Una mejora sería muestrear por reseña, segmentar por oraciones dentro del límite de tokens y comparar modelos de embeddings con una evaluación humana ciega.

Bonus opcional y uso de IA

No se ejecutó la comparación BERTopic contra un LLM por API. Se utilizó IA generativa para localizar fuentes, escribir y depurar código. Los embeddings, agrupamientos, ejemplos y métricas proceden de ejecución local real.

12. Bibliografía y acceso al código

1. Riyosha (2024). Letterboxd Movie Reviews (~90,000), versión 1. Kaggle.

https://www.kaggle.com/datasets/riyosha/letterboxd-movie-reviews-90000

2. Sentence Transformers. Ficha del modelo paraphrase-multilingual-MiniLM-L12-v2.

https://huggingface.co/sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2

3. Grootendorst, M. BERTopic: The Algorithm. Documentación oficial.

https://maartengr.github.io/BERTopic/algorithm/algorithm.html

4. BERTopic. Parameter tuning. Documentación oficial.

https://maartengr.github.io/BERTopic/getting_started/parameter%20tuning/parametertuning.html

5. NLTK. Repositorio nltk_data: stopwords.

https://github.com/nltk/nltk_data/blob/gh-pages/packages/corpora/stopwords.xml

6. BERTopic. Outlier reduction. Documentación oficial.

https://maartengr.github.io/BERTopic/getting_started/outlier_reduction/outlier_reduction.html

Fuentes consultadas el 30 de octubre de 2026. La revisión exacta del encoder está en data/embedding_metadata.json; el hash SHA-256 del CSV y el embudo de selección están en results/segmentation.json.

Repositorio del proyecto

GITHUB · CÓDIGO Y REPRODUCCIÓN

ErikJajan / BERTopic
https://github.com/ErikJajan/BERTopic

Código de adquisición, segmentación, modelado y generación del reporte; guía de ejecución, tablas y catálogos de tópicos.